

Roteiro de Aula

Ollama

Objetivo

Apresentar a ferramenta Ollama, uma das opções para rodar modelos de linguagem de larga escala (LLMs) em computadores locais.

O que você vai aprender

1. Baixar e instalar a ferramenta Ollama
2. Baixar modelos da biblioteca de modelos Ollama
3. Rodar os modelos em computadores locais por linha de comandos
4. Rodar os modelos em computadores locais usando a linguagem Python
5. Usar a API nativa do Ollama e a API compatível com a OpenAI
6. Configurar uma interface Web estilo ChatGPT com a Open WebUI

Conceitos

Ollama <https://ollama.com/>

Ollama é um framework de código aberto que simplifica a execução de modelos de linguagem de larga escala em computadores locais. Isso permite que desenvolvedores e pesquisadores trabalhem com LLMs sem depender de servidores externos, oferecendo maior controle sobre dados e custos.

Instruções

Estude e execute o código do tutorial “Ollama Tutorial: Running LLMs Locally Made Super Simple” do link abaixo:

<https://www.kdnuggets.com/ollama-tutorial-running-llms-locally-made-super-simple>

Estude e execute o código do artigo “LLM Zero-to-Hero with Ollama” do link abaixo:

<https://blog.cubed.run/llm-zero-to-hero-with-ollama-913e50d6b7f0>

Referências

Ollama Tutorial: Running LLMs Locally Made Super Simple

<https://www.kdnuggets.com/ollama-tutorial-running-llms-locally-made-super-simple>

LLM Zero-to-Hero with Ollama

<https://blog.cubed.run/llm-zero-to-hero-with-ollama-913e50d6b7f0>