

Roteiro de Aula

Llama.cpp

Objetivo

Apresentar a ferramenta Llama.cpp, uma das opções para rodar modelos de linguagem de larga escala (LLMs) em computadores locais.

O que você vai aprender

1. Baixar e instalar a ferramenta Llama.cpp
2. Baixar modelos no formato GGUF e converter modelos para esse formato
3. Rodar modelos em computadores locais usando a linguagem Python
4. Rodar o Llama.cpp como um servidor

Conceitos

Llama.cpp <https://github.com/ggml-org/llama.cpp>

Llama.cpp é um framework de código aberto que simplifica a execução de modelos de linguagem de larga escala em computadores locais. Isso permite que desenvolvedores e pesquisadores trabalhem com LLMs sem depender de servidores externos, oferecendo maior controle sobre dados e custos.

Instruções

Estude e execute o código do artigo “Running LLaMA Locally with Llama.cpp: A Complete Guide” do link abaixo:

<https://medium.com/hydroinformatics/running-llama-locally-with-llama-cpp-a-complete-guide-adb5f7a2e2ec>

Referência

Running LLaMA Locally with Llama.cpp: A Complete Guide

<https://medium.com/hydroinformatics/running-llama-locally-with-llama-cpp-a-complete-guide-adb5f7a2e2ec>