

Roteiro de Aula

Chatbot Fine-Tuning

Objetivo

Apresentar um exemplo de um notebook em Python para fazer o ajuste fino (*fine-tuning*) de um modelo de linguagem para a tarefa de assistente virtual.

O que você vai aprender

1. Usar as ferramentas Unsloth e Ollama
2. Selecionar um modelo para o fine-tuning
3. Configurar os parâmetros a serem ajustados, por meio do PEFT (*Parameter-Efficient Fine-Tuning*)
4. Usar o dataset Alpaca com conversas de um chatbot
5. Treinar e salvar o modelo ajustado

Conceitos

Unsloth <https://unsloth.ai/>

Unsloth AI é uma biblioteca em Python projetada para ajuste fino rápido e acesso a grandes modelos de linguagem. Ela oferece uma API simples e com um desempenho duas vezes mais rápido em comparação com o Transformers.

Ollama <https://ollama.com/>

Ollama é uma ferramenta de código aberto que simplifica a execução de modelos de linguagem (LLMs) em computadores locais. Isso permite que desenvolvedores e pesquisadores trabalhem com LLMs sem depender de servidores externos, oferecendo maior controle sobre dados e custos.

PEFT (*Parameter-Efficient Fine-Tuning*) <https://huggingface.co/blog/peft>

PEFT é uma técnica que permite adaptar um modelo de linguagem de larga escala (LLM) pré-treinado a tarefas ou conjuntos de dados específicos sem precisar ajustar todos os seus parâmetros. Ao treinar apenas um pequeno subconjunto dos parâmetros do modelo, o PEFT reduz significativamente o custo computacional e os requisitos de armazenamento, ao mesmo tempo em que alcança um desempenho comparável ao ajuste fino completo.

Instruções

Veja passo-a-passo o tutorial “How to Finetune Llama-3 and Use In Ollama” no link abaixo e o notebook com o código do exemplo no link seguinte.

<https://docs.unsloth.ai/basics/tutorial-how-to-finetune-llama-3-and-use-in-ollama>

[https://colab.research.google.com/github/unslothai/notebooks/blob/main/nb/Llama3_\(8B\)-Ollama.ipynb#scrollTo=yFfaXG0WsQuE](https://colab.research.google.com/github/unslothai/notebooks/blob/main/nb/Llama3_(8B)-Ollama.ipynb#scrollTo=yFfaXG0WsQuE)

Execute o notebook, faça pequenas mudanças e avalie o resultado.

Veja outros exemplos de fine-tuning de chatbots:

<https://labelstud.io/blog/fine-tuning-llama-3-enhancing-accuracy-in-medical-q-and-a-with-llms/>

Referências

Tutorial: How to Finetune Llama-3 and Use In Ollama

<https://docs.unsloth.ai/basics/tutorial-how-to-finetune-llama-3-and-use-in-ollama>

Ollama Tutorial: Running LLMs Locally Made Super Simple

<https://www.kdnuggets.com/ollama-tutorial-running-llms-locally-made-super-simple>

Parameter-Efficient Fine-Tuning Methods for Pretrained Language Models: A Critical Review and Assessment

<https://arxiv.org/abs/2312.12148>