

Roteiro de Aula

RAG - Retrieval-Augmented Generation

Objetivo

Apresentar o conceito de RAG e um exemplo simples de implementação.

O que você vai aprender

1. Aplicar os conceitos de RAG em uma implementação básica
2. Usar um modelo de linguagem para codificar, na forma de *embeddings*, uma base de conhecimento textual
3. Criar um banco de dados vetorial para armazenar os embeddings da base de conhecimento
4. Gerar o contexto para responder consultas do usuário a partir dos embeddings da base de conhecimento
5. Usar um modelo de linguagem pré-treinado para responder as consultas do usuário

Conceitos

RAG - Retrieval-Augmented Generation

RAG - Geração Aumentada de Recuperação - é uma técnica de recuperação de informação que permite o uso de um *Large Language Model* (LLM) para responder perguntas sobre documentos em uma base de dados específica (da sua empresa, por exemplo).

Instruções

Assista às duas videoaulas dos links a seguir.

[Vídeo iaa-rag-02a](#): Princípio de funcionamento do RAG

[Vídeo iaa-rag-02b](#): Exemplo básico em Python de como implementar um sistema de RAG

Execute o notebook em Python do seguinte link:

[Notebook em Python](#): Exemplo 2

Referências

RAG with LLaMA Using Ollama: A Deep Dive into Retrieval-Augmented Generation

<https://medium.com/@danushidk507/rag-with-llama-using-ollama-a-deep-dive-into-retrieval-augmented-generation-c58b9a1cfd3>

O que é a geração aumentada de recuperação?

<https://aws.amazon.com/pt/what-is/retrieval-augmented-generation/>

Code a simple RAG from scratch

<https://huggingface.co/blog/ngxson/make-your-own-rag>